

Detecção inteligente de efeitos colaterais indesejáveis na Internet das coisas - um estudo de caso no Home Network System

Apresentação de Monografia

Heron Sanches Gonçalves Pires Ferreira



Universidade Federal da Bahia - Departamento de Ciência da Computação

Orientadora: Profa. Dra. Daniela Barreiro Claro

Co-Orientador: Roberto Cerqueira Figueiredo

Contato: heronsanches@dcc.ufba.br

31 de outubro de 2016

Conteúdo

1 Introdução

2 Proposta

- Cenário Levar compras
- Método de detecção
 - Geração da massa de dados
 - Seleção dos atributos
 - Método ensemble DECORATE
- Implantação do método proposto

3 Validação

- Método avaliativo stratified-k-fold-cross-validation
- Experimentos
- Resultados e discussão
 - Modelos
 - Implantação

4 Conclusão e trabalhos futuros

Conteúdo

1 Introdução

2 Proposta

- Cenário Levar compras
- Método de detecção
 - Geração da massa de dados
 - Seleção dos atributos
 - Método ensemble DECORATE
- Implantação do método proposto

3 Validação

- Método avaliativo stratified-k-fold-cross-validation
- Experimentos
- Resultados e discussão
 - Modelos
 - Implantação

4 Conclusão e trabalhos futuros

Introdução

- A Internet está se tornando cada vez mais persistente no cotidiano (??).
- Em 2010 havia aproximadamente 1,5 bilhão de PCs conectados a Internet e mais que 1 bilhão de telefones móveis (??).
- Segundo Gartner¹, 6,4 bilhões de coisas estarão conectadas até o final de 2016 e, em 2020 esse número atingirá cerca de 20,8 bilhões.

¹<<http://www.gartner.com/newsroom/id/3165317>>

Introdução

- A Internet está se tornando cada vez mais persistente no cotidiano (??).
- Em 2010 havia aproximadamente 1,5 bilhão de PCs conectados a Internet e mais que 1 bilhão de telefones móveis (??).
- Segundo Gartner¹, 6,4 bilhões de coisas estarão conectadas até o final de 2016 e, em 2020 esse número atingirá cerca de 20,8 bilhões.

¹<<http://www.gartner.com/newsroom/id/3165317>>

Introdução

- A Internet está se tornando cada vez mais persistente no cotidiano (??).
- Em 2010 havia aproximadamente 1,5 bilhão de PCs conectados a Internet e mais que 1 bilhão de telefones móveis (??).
- Segundo Gartner¹, 6,4 bilhões de coisas estarão conectadas até o final de 2016 e, em 2020 esse número atingirá cerca de 20,8 bilhões.

¹<<http://www.gartner.com/newsroom/id/3165317>>

Coisa: veículo, animal, dispositivo doméstico, pessoa, ...




Imagem: Baseada em (??)

Internet das Coisas (IoT)

Devido ao crescente número de coisas sendo conectadas, surgem diversos desafios, a exemplo de:

- Disponibilidade de uma interface de comunicação (acesso aos serviços e informações dos dispositivos) comum aos objetos.
- Detecção e resolução de efeitos colaterais indesejáveis.

Internet das Coisas (IoT)

Devido ao crescente número de coisas sendo conectadas, surgem diversos desafios, a exemplo de:

- Disponibilidade de uma interface de comunicação (acesso aos serviços e informações dos dispositivos) comum aos objetos.
- Detecção e resolução de efeitos colaterais indesejáveis.

Desafios IoT: interface de comunicação padrão

Disponibilização das coisas como serviços Web RESTful.

- Mais leve que os serviços Web baseados em SOAP.

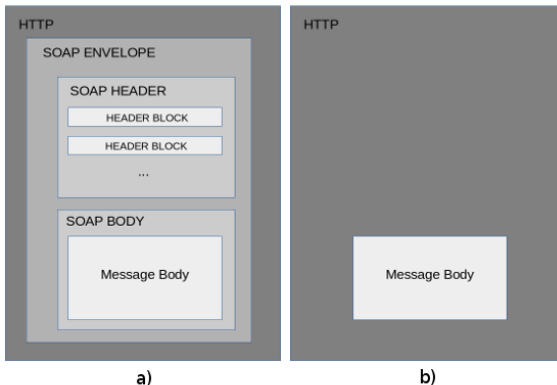


Imagem: Baseada em (??)

Desafios IoT: interface de comunicação padrão

Disponibilização das coisas como serviços Web RESTFul.

- Diferentes representações de um mesmo recurso (aumenta a interoperabilidade)

Exemplos

JSON, XML, TEXT, TEXT_HTML.

- Interface com semântica bem definida.

Exemplos

Utilização dos métodos HTTP (GET, PUT, DELETE, POST, HEAD, OPTIONS, dentre outros).

Desafios IoT: interface de comunicação padrão

Disponibilização das coisas como serviços Web RESTFul.

- Diferentes representações de um mesmo recurso (aumenta a interoperabilidade)

Exemplos

JSON, XML, TEXT, TEXT_HTML.

- Interface com semântica bem definida.

Exemplos

Utilização dos métodos HTTP (GET, PUT, DELETE, POST, HEAD, OPTIONS, dentre outros).

Desafios IoT: detecção e resolução de efeitos colaterais indesejáveis

Em desenvolvimento de *software*, uma *feature* (característica) é um componente de adicional funcionalidade ao *software* (??), consistindo de um conjunto de requisitos logicamente relacionados e suas especificações, o qual se destina a fornecer um determinado efeito comportamental (??).

Desafios IoT: detecção e resolução de efeitos colaterais indesejáveis

Quando a **composição de *features*** leva a algum **comportamento não esperado** - interação de características, esta pode resultar em **efeitos colaterais indesejáveis**: um estado inconsistente do sistema, um sistema instável ou dados imprecisos (??).

Conteúdo

1 Introdução

2 Proposta

- Cenário Levar compras
- Método de detecção
 - Geração da massa de dados
 - Seleção dos atributos
 - Método ensemble DECORATE
- Implantação do método proposto

3 Validação

- Método avaliativo stratified-k-fold-cross-validation
- Experimentos
- Resultados e discussão
 - Modelos
 - Implantação

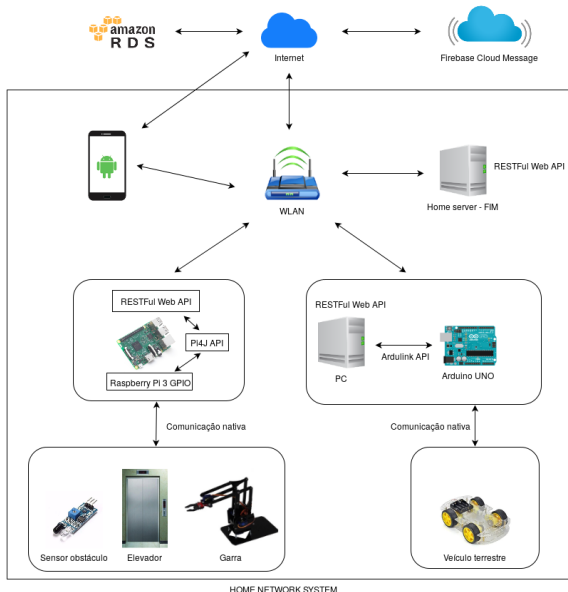
4 Conclusão e trabalhos futuros

Proposta

Detectar efeitos colaterais indesejáveis de uma maneira inteligente, utilizando o método *ensemble* DECORATE, no cenário “Levar compras” do *Home Network System* (HNS).

Rede doméstica de coisas (aparelhos domésticos e sensores) com capacidade de conectividade de rede e, interface de controle e monitoramento. Os dispositivos da casa são compostos uns com os outros para prover funcionalidades que atendam aos requisitos dos usuários da casa (??).

HNS do Cenário Levar compras



Objetos das compras (cestas)

largura	altura	comprimento	massa	diâmetro	nome
0	0.031	0	0.003	0.009	Refrigerante nº 4 - Soda
0.01	0.014	0.03	0.001	0	Caixa Pasta de dente - vermelha.
0.004	0.02	0.014	0.001	0	Batata
0.004	0.02	0.014	0.001	0	Café
0	0.015	0	0.003	0.008	Café Classic
0.005	0.02	0.011	0.001	0	Cerveja em lata III
0	0.028	0	0.001	0.007	Champanhe - Azul
0.004	0.02	0.014	0.001	0	Farinha de Trigo
0	0.03	0	0.001	0.008	Garrafa de Rum
0.012	0.016	0.004	0.004	0	Goiabada
0	0.03	0	0.001	0.008	Garrafa de Vodka Special
0.027	0.014	0.018	0.001	0	Pote de sorvete
0	0.032	0	0.002	0.007	Vinho branco
0.012	0.03	0.006	0.002	0	Limpa vidros
0.021	0.015	0.007	0.002	0	Sabonete - II
0.015	0.024	0.008	0.001	0	Sabão em pó - II
0.019	0.03	0.039	0.018	0	Bau simples
0.046	0.061	0.017	0.006	0	Prateleira de acrílico pequena
0.016	0.025	0.004	0.001	0	Farinha de trigo
0	0.03	0	0.003	0.022	Barril em madeira
0.013	0.017	0.0063	0.002	0	Fermento em pó
0.077	0.0197	0.038	0.001	0	Colchão p/ berço azul
0.01	0.0432	0	0.001	0	Jogo de esfregões
0.0181	0.0258	0.0017	0.001	0	Pão de Queijo
0.022	0.0412	0.0135	0.001	0	Rastelo

Imagem: Objetos das compras (cestas). Medidas em metros (m).

Exemplos de Compras (cestas)



Imagem: Exemplos de cestas.

Cenário Levar compras

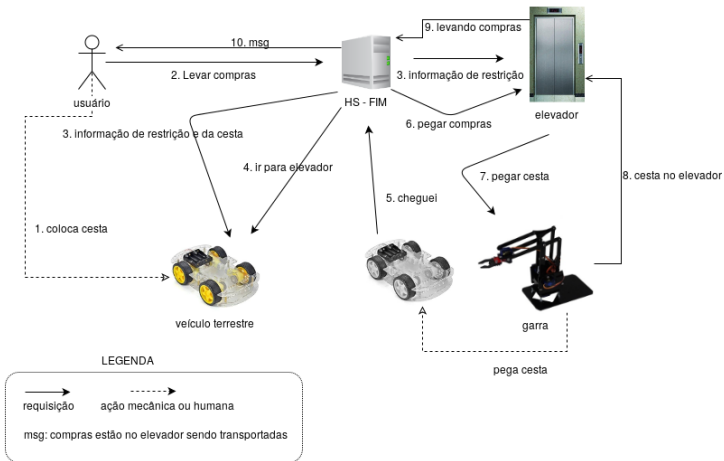


Imagem: Cenário Levar compras.

Geração da massa de dados

- Confeccionadas 59 cestas.
- Verificado se as cestas cabiam dentro do elevador.
- Registro no banco de dados relacional na nuvem.
- Cenário Levar compras executado 59 vezes.

Geração da massa de dados

- Confeccionadas 59 cestas.
- Verificado se as cestas cabiam dentro do elevador.
- Registro no banco de dados relacional na nuvem.
- Cenário Levar compras executado 59 vezes.

Geração da massa de dados

- Confeccionadas 59 cestas.
- Verificado se as cestas cabiam dentro do elevador.
- Registro no banco de dados relacional na nuvem.
- Cenário Levar compras executado 59 vezes.

Geração da massa de dados

- Confeccionadas 59 cestas.
- Verificado se as cestas cabiam dentro do elevador.
- Registro no banco de dados relacional na nuvem.
- Cenário Levar compras executado 59 vezes.

Geração da massa de dados

- Algumas vezes o comportamento da garra fazia com que a cesta não ficasse corretamente no compartimento do elevador, impedindo o elevador continuar com a funcionalidade “Levar compras”. Provocando um **efeito colateral indesejável**.
- Cada cesta foi rotulada como “É efeito colateral” ou “não é efeito colateral” e atualizado valor no banco.

Geração da massa de dados

- Algumas vezes o comportamento da garra fazia com que a cesta não ficasse corretamente no compartimento do elevador, impedindo o elevador continuar com a funcionalidade “Levar compras”. Provocando um **efeito colateral indesejável**.
- Cada cesta foi rotulada como “**É efeito colateral**” ou “**não é efeito colateral**” e atualizado valor no banco.

Seleção dos atributos

- Uma cesta com 10 objetos tem $10 \times 5 = 50$ atributos.
- Usado os valores das médias e totais das medidas, assim como a quantidade de objetos. Reduzindo a 11 atributos.

Seleção dos atributos

- Uma cesta com 10 objetos tem $10 \times 5 = 50$ atributos.
- Usado os valores das médias e totais da medidas, assim como a quantidade de objetos. Reduzindo a 11 atributos.

Seleção dos atributos

- Construído arquivo “arff”, padrão WEKA (??), com 59 instâncias.
- Cada instância representa uma cesta com 11 parâmetros numéricos mais 1 nominal.
- Gerou-se uma visualização do espaço de atributos em 2D, ou seja, par a par.

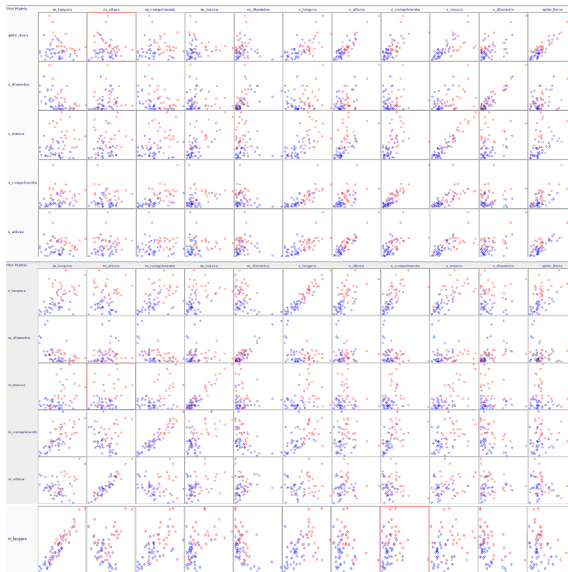
Seleção dos atributos

- Construído arquivo “arff”, padrão WEKA (??), com 59 instâncias.
- Cada instância representa uma cesta com 11 parâmetros numéricos mais 1 nominal.
- Gerou-se uma visualização do espaço de atributos em 2D, ou seja, par a par.


Seleção dos atributos

- Construído arquivo “arff”, padrão WEKA (??), com 59 instâncias.
- Cada instância representa uma cesta com 11 parâmetros numéricos mais 1 nominal.
- Gerou-se uma visualização do espaço de atributos em 2D, ou seja, par a par.

Seleção dos atributos



Seleção dos atributos - 3 pares selecionados



DECORATE (???????)

DECORATE (Diverse Ensemble Creation by Oppositional Relabeling of Artificial Training Examples).

- Combina o resultado de diversos classificadores para chegar em uma decisão final.

$$P_y(x) = \frac{\sum_{C_i \in C^*} P_{C_i, y}(x)}{|C^*|} \quad (1)$$

DECORATE

- Utiliza dados adicionais de treino gerados artificialmente.




Imagem: Curva Gaussiana. ³

³<<http://proooof.blogspot.com.br/2011/12/sigma.html>>

DECORATE

- Utiliza dados adicionais de treino gerados artificialmente.
- Primeiramente utiliza a probabilidade do *ensemble* $P_y(x)$.
- Por fim utiliza a expressão abaixo para rotular o exemplo artificial.

$$P_y^{-1}(x) = \frac{\frac{1}{P_y(x)}}{\sum_y \frac{1}{P_y(x)}} \quad (2)$$

DECORATE

- Utiliza dados adicionais de treino gerados artificialmente.
- Primeiramente utiliza a probabilidade do *ensemble* $P_y(x)$.
- Por fim utiliza a expressão abaixo para rotular o exemplo artificial.

$$P_y^{-1}(x) = \frac{\frac{1}{P_y(x)}}{\sum_y \frac{1}{P_y(x)}} \quad (2)$$

DECORATE




Imagem: DECORATE 1ª iteração. ⁴

⁴ <<http://www.time.mk/trajkovski/teaching/aim/Lecture8.pdf>>

DECORATE




Imagem: DECORATE 2ª iteração. ⁵

⁵<<http://www.time.mk/trajkovski/teaching/aim/Lecture8.pdf>>

Parâmetros DECORATE (??)

- Número máximo de iterações = 50.
- Número máximo de classificadores = 14.
- Classificador base = J48.
- Quantidade de exemplos artificiais = 100% do *dataset* de treino.

Parâmetros DECORATE (??)

- Número máximo de iterações = 50.
- Número máximo de classificadores = 14.
- Classificador base = J48.
- Quantidade de exemplos artificiais = 100% do *dataset* de treino.

Parâmetros DECORATE (??)

- Número máximo de iterações = 50.
- Número máximo de classificadores = 14.
- Classificador base = J48.
- Quantidade de exemplos artificiais = 100% do *dataset* de treino.

Parâmetros DECORATE (??)

- Número máximo de iterações = 50.
- Número máximo de classificadores = 14.
- Classificador base = J48.
- Quantidade de exemplos artificiais = 100% do *dataset* de treino.

Implantação do método proposto




Imagem: Atuação do DECORATE no cenário Levar compras.

Conteúdo

1 Introdução

2 Proposta

- Cenário Levar compras
- Método de detecção
 - Geração da massa de dados
 - Seleção dos atributos
 - Método ensemble DECORATE
- Implantação do método proposto

3 Validação

- Método avaliativo stratified-k-fold-cross-validation
- Experimentos
- Resultados e discussão
 - Modelos
 - Implantação

4 Conclusão e trabalhos futuros

TP, TN, FP, FN (??)

- Verdadeiro positivo (TP): instância que pertence a classe positiva e que foi corretamente classificada como positiva.
- Verdadeiro negativo (TN): instância que pertence a classe negativa e que foi classificada corretamente como negativa.
- Falso positivo (FP): instância que pertence a classe negativa e que foi classificada incorretamente como positiva.
- Falso negativo (FN): instância que pertence a classe positiva e que foi classificada incorretamente como negativa.

TP, TN, FP, FN (??)

- Verdadeiro positivo (TP): instância que pertence a classe positiva e que foi corretamente classificada como positiva.
- Verdadeiro negativo (TN): instância que pertence a classe negativa e que foi classificada corretamente como negativa.
- Falso positivo (FP): instância que pertence a classe negativa e que foi classificada incorretamente como positiva.
- Falso negativo (FN): instância que pertence a classe positiva e que foi classificada incorretamente como negativa.

TP, TN, FP, FN (??)

- Verdadeiro positivo (TP): instância que pertence a classe positiva e que foi corretamente classificada como positiva.
- Verdadeiro negativo (TN): instância que pertence a classe negativa e que foi classificada corretamente como negativa.
- Falso positivo (FP): instância que pertence a classe negativa e que foi classificada incorretamente como positiva.
- Falso negativo (FN): instância que pertence a classe positiva e que foi classificada incorretamente como negativa.

TP, TN, FP, FN (??)

- Verdadeiro positivo (TP): instância que pertence a classe positiva e que foi corretamente classificada como positiva.
- Verdadeiro negativo (TN): instância que pertence a classe negativa e que foi classificada corretamente como negativa.
- Falso positivo (FP): instância que pertence a classe negativa e que foi classificada incorretamente como positiva.
- Falso negativo (FN): instância que pertence a classe positiva e que foi classificada incorretamente como negativa.

Accuracy (??)

- *Accuracy*: taxa correta de classificação em relação a todos os exemplos.

$$Accuracy = \frac{TP + TN}{TP + TN + FP + FN} \quad (3)$$

Precision, Recall (??)

- *Precision*: Dentre todos os exemplos classificados como positivos, quais realmente são positivos ?

$$Precision = \frac{TP}{TP + FP} \quad (4)$$

- *Recall* ou *True Positive Rate* - *TPR*: Dentre os exemplos classificados como positivos (que realmente são positivos) e os classificados como negativos (mas que são positivos), qual a taxa de exemplos positivos classificados corretamente?

$$Recall = \frac{TP}{TP + FN} \quad (5)$$

Precision, Recall (??)

- *Precision*: Dentre todos os exemplos classificados como positivos, quais realmente são positivos ?

$$Precision = \frac{TP}{TP + FP} \quad (4)$$

- *Recall* ou *True Positive Rate* - *TPR*: Dentre os exemplos classificados como positivos (que realmente são positivos) e os classificados como negativos (mas que são positivos), qual a taxa de exemplos positivos classificados corretamente?

$$Recall = \frac{TP}{TP + FN} \quad (5)$$

stratified-k-fold-cross-validation




Imagem: k-fold-cross-validation. Adaptado de (??).

Experimentos

- Para cada par de atributos selecionados utilizou-se *stratified-10-fold-cross-validation* (repetido dez vezes) juntamente com o *ensemble DECORATE* a fim de verificar se é possível generalizar pelo menos um modelo.
- Em cada verificação construiu-se um modelo com diferentes frações do dataset, variando de 16 instâncias a 59 instâncias e, construiu-se uma curva de aprendizado.
- Selecionou-se a curva que mais crescia e se mantia regular e, com melhor taxa de *recall*.
- Verificou a partir de que ponto esta curva tinha os melhores valores de *recall*, *precision* e *accuracy*.
- Realizou um procedimento de geração de modelo final a partir desse melhor ponto.

Experimentos

- Para cada par de atributos selecionados utilizou-se *stratified-10-fold-cross-validation* (repetido dez vezes) juntamente com o *ensemble DECORATE* a fim de verificar se é possível generalizar pelo menos um modelo.
- Em cada verificação construiu-se um modelo com diferentes frações do dataset, variando de 16 instâncias a 59 instâncias e, construiu-se uma curva de aprendizado.
- Selecionou-se a curva que mais crescia e se mantia regular e, com melhor taxa de *recall*.
- Verificou a partir de que ponto esta curva tinha os melhores valores de *recall*, *precision* e *accuracy*.
- Realizou um procedimento de geração de modelo final a partir desse melhor ponto.

Experimentos

- Para cada par de atributos selecionados utilizou-se *stratified-10-fold-cross-validation* (repetido dez vezes) juntamente com o *ensemble DECORATE* a fim de verificar se é possível generalizar pelo menos um modelo.
- Em cada verificação construiu-se um modelo com diferentes frações do dataset, variando de 16 instâncias a 59 instâncias e, construiu-se uma curva de aprendizado.
- Selecionou-se a curva que mais crescia e se mantia regular e, com melhor taxa de *recall*.
- Verificou a partir de que ponto esta curva tinha os melhores valores de *recall*, *precision* e *accuracy*.
- Realizou um procedimento de geração de modelo final a partir desse melhor ponto.







Experimentos

- Para cada par de atributos selecionados utilizou-se *stratified-10-fold-cross-validation* (repetido dez vezes) juntamente com o *ensemble DECORATE* a fim de verificar se é possível generalizar pelo menos um modelo.
- Em cada verificação construiu-se um modelo com diferentes frações do dataset, variando de 16 instâncias a 59 instâncias e, construiu-se uma curva de aprendizado.
- Selecionou-se a curva que mais crescia e se mantia regular e, com melhor taxa de *recall*.
- Verificou a partir de que ponto esta curva tinha os melhores valores de *recall*, *precision* e *accuracy*.
- Realizou um procedimento de geração de modelo final a partir desse melhor ponto.

Experimentos

- Para cada par de atributos selecionados utilizou-se *stratified-10-fold-cross-validation* (repetido dez vezes) juntamente com o *ensemble DECORATE* a fim de verificar se é possível generalizar pelo menos um modelo.
- Em cada verificação construiu-se um modelo com diferentes frações do dataset, variando de 16 instâncias a 59 instâncias e, construiu-se uma curva de aprendizado.
- Selecionou-se a curva que mais crescia e se mantia regular e, com melhor taxa de *recall*.
- Verificou a partir de que ponto esta curva tinha os melhores valores de *recall*, *precision* e *accuracy*.
- Realizou um procedimento de geração de modelo final a partir desse melhor ponto.

Resultados: 10×stratified-10-fold-cross-validation



Resultados: curva de aprendizado selecionada

$n^{\circ}i$	40	45	50	55	58
A, DP	92.5, 0	92.75, 1.78	88.8, 1.6	91.13, 1.56	92.33, 1.89
P, DP	93.5, 2.29	99.17, 1.71	93.17, 2.93	92.17, 3.25	92.5, 2.81
R, DP	91.69, 2.56	90.25, 2.21	86.33, 1.91	89.71, 2.97	92.05, 3.06

Tabela: Valores das curvas “ma x sl” da Figura 15 a partir do *dataset* com 40 instâncias. A (*Accuracy*), P (*Precision*), R (*Recall*), DP (Desvio Padrão), i (instâncias). Os valores A, P, R e DV estão em %.

$$(accuracy \geq (92.75 - 1.78)) \wedge (precision \geq (99.17 - 1.71)) \wedge (recall \geq 90.25) \quad (6)$$

Resultados: geração do modelo final





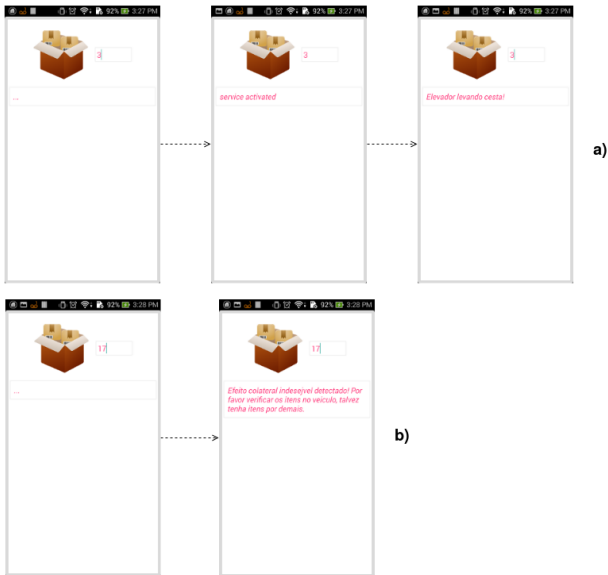
Imagem: *stratified-10-fold-cross-validation* (repetido dez vezes). 45 instâncias foram escolhidas randomicamente em cima do *dataset* de 59 instâncias. Procedimento repetido até que satisfizesse a expressão 6.

Resultados: geração do modelo final

		Desvio Padrão %
Accuracy %	98.05	1.81
Precision %	98.5	3.2
Recall %	97.67	2

Tabela: Valores da validação do modelo final.

Resultados: Implantação do modelo final



Conteúdo

1 Introdução

2 Proposta

- Cenário Levar compras
- Método de detecção
 - Geração da massa de dados
 - Seleção dos atributos
 - Método ensemble DECORATE
- Implantação do método proposto

3 Validação

- Método avaliativo stratified-k-fold-cross-validation
- Experimentos
- Resultados e discussão
 - Modelos
 - Implantação

4 Conclusão e trabalhos futuros

Conclusão

- Foi construído o cenário “Levar compras” no HNS.
- A composição de dispositivos provocou efeitos colaterais indesejáveis no cenário “Levar compras”.
- Obteve-se um modelo baseado no *ensemble* DECORATE com alto grau de generalização em um *dataset* de treino com 45 instâncias com os valores de *Accuracy* = 98.05%, *Precision* = 98.5% e *Recall* = 97.67%.
- Modelo foi implantado no FIM do HNS, desta forma ficou apto a realizar detecção inteligente de efeitos colaterais indesejáveis.

Conclusão

- Foi construído o cenário “Levar compras” no HNS.
- A composição de dispositivos provocou efeitos colaterais indesejáveis no cenário “Levar compras”.
- Obteve-se um modelo baseado no *ensemble* DECORATE com alto grau de generalização em um *dataset* de treino com 45 instâncias com os valores de *Accuracy* = 98.05%, *Precision* = 98.5% e *Recall* = 97.67%.
- Modelo foi implantado no FIM do HNS, desta forma ficou apto a realizar detecção inteligente de efeitos colaterais indesejáveis.

Conclusão

- Foi construído o cenário “Levar compras” no HNS.
- A composição de dispositivos provocou efeitos colaterais indesejáveis no cenário “Levar compras”.
- Obteve-se um modelo baseado no *ensemble* DECORATE com alto grau de generalização em um *dataset* de treino com 45 instâncias com os valores de *Accuracy* = 98.05%, *Precision* = 98.5% e *Recall* = 97.67%.
- Modelo foi implantado no FIM do HNS, desta forma ficou apto a realizar detecção inteligente de efeitos colaterais indesejáveis.

Conclusão

- Foi construído o cenário “Levar compras” no HNS.
- A composição de dispositivos provocou efeitos colaterais indesejáveis no cenário “Levar compras”.
- Obteve-se um modelo baseado no *ensemble* DECORATE com alto grau de generalização em um *dataset* de treino com 45 instâncias com os valores de *Accuracy* = 98.05%, *Precision* = 98.5% e *Recall* = 97.67%.
- Modelo foi implantado no FIM do HNS, desta forma ficou apto a realizar detecção inteligente de efeitos colaterais indesejáveis.

Trabalhos futuros

- Realizar estudo sobre algoritmos de seleção de atributos e aplicar os algoritmos no cenário “Levar compras”, realizando comparações dos resultados obtidos com o os resultados deste trabalho.
- Criar cenário mais complexo, com pouca ou nenhuma intervenção humana e, realizar os mesmos testes anteriores.
- Realizar estudos sobre aprendizado não supervisionado e prover metodologia para realizar classificação de efeitos colaterais indesejáveis e, realizar os mesmos testes e comparações nos dois cenários anteriores.

Trabalhos futuros

- Realizar estudo sobre algoritmos de seleção de atributos e aplicar os algoritmos no cenário “Levar compras”, realizando comparações dos resultados obtidos com o os resultados deste trabalho.
- Criar cenário mais complexo, com pouca ou nenhuma intervenção humana e, realizar os mesmos testes anteriores.
- Realizar estudos sobre aprendizado não supervisionado e prover metodologia para realizar classificação de efeitos colaterais indesejáveis e, realizar os mesmos testes e comparações nos dois cenários anteriores.


Trabalhos futuros

- Realizar estudo sobre algoritmos de seleção de atributos e aplicar os algoritmos no cenário “Levar compras”, realizando comparações dos resultados obtidos com o os resultados deste trabalho.
- Criar cenário mais complexo, com pouca ou nenhuma intervenção humana e, realizar os mesmos testes anteriores.
- Realizar estudos sobre aprendizado não supervisionado e prover metodologia para realizar classificação de efeitos colaterais indesejáveis e, realizar os mesmos testes e comparações nos dois cenários anteriores.


Obrigado Pela Atenção!

Perguntas?


Referências I

 Mudança de estilo após este ponto com o comando `\citeoption{abnt-show-options=list}` . Opção selecionada `abnt-show-options=list`.

```
@abnt-options{abnt-show-options=list,  
key={aaaa},  
abnt-show-options={list}}
```


 Mudança de estilo após este ponto com o comando `\citeoption{abnt-substyle=none}` .

```
@abnt-options{abnt-substyle=none,  
key={aaaa}}
```


 Mudança de estilo após este ponto com o comando `\citeoption{abnt-substyle=UFLA}` . Opção selecionada `abnt-and-type=&`. Opção selecionada `abnt-etal-cite=2`. Opção selecionada `abnt-etal-list=0`.

```
@abnt-options{abnt-substyle=UFLA,  
key={aaaa}}
```


Referências II

 Mudança de estilo após este ponto com o comando `\citeoption{abnt-substyle=COPPE}` . Opção selecionada `abnt-title-command=yes`.

```
@abnt-options{abnt-substyle=COPPE,  
key={aaaa},  
abnt-title-command={yes}}
```

 Mudança de estilo após este ponto com o comando `\citeoption{abnt-thesis-year=final}` . Opção selecionada `abnt-thesis-year=final`.

```
@abnt-options{abnt-thesis-year=final,  
key={aaaa},  
abnt-thesis-year={final}}
```

 Mudança de estilo após este ponto com o comando `\citeoption{abnt-thesis-year=title}` . Opção selecionada `abnt-thesis-year=title`.

```
@abnt-options{abnt-thesis-year=title,  
key={aaaa},  
abnt-thesis-year={title}}
```

Referências III



Mudança de estilo após este ponto com o comando `\citeoption{abnt-thesis-year=both}` . Opção selecionada `abnt-thesis-year=both`.

```
@abnt-options{abnt-thesis-year=both,  
key={aaaa},  
abnt-thesis-year={both}}
```



Mudança de estilo após este ponto com o comando `\citeoption{abnt-title-command=no}` . Opção selecionada `abnt-title-command=no`.

```
@abnt-options{abnt-title-command=no,  
key={aaaa},  
abnt-title-command={no}}
```



Mudança de estilo após este ponto com o comando `\citeoption{abnt-title-command=yes}` . Opção selecionada `abnt-title-command=yes`.

```
@abnt-options{abnt-title-command=yes,  
key={aaaa},  
abnt-title-command={yes}}
```

Referências IV



Mudança de estilo após este ponto com o comando `\citeoption{abnt-url-package=none}` . Opção selecionada `abnt-url-package=none`.

```
@abnt-options{abnt-url-package=none,  
key={aaaa},  
abnt-url-package={none}}
```




Mudança de estilo após este ponto com o comando `\citeoption{abnt-url-package=hyperref}` . Opção selecionada `abnt-url-package=hyperref`.


```
@abnt-options{abnt-url-package=hyperref,  
key={aaaa},  
abnt-url-package={hyperref}}
```




Mudança de estilo após este ponto com o comando `\citeoption{abnt-verbatim-entry=no}` . Opção selecionada `abnt-verbatim-entry=no`.


Referências V


 Mudança de estilo após este ponto com o comando `\citeoption{iso-690-1987}` . Opção selecionada `abnt-cite-style=(Author, YEAR)`. Opção selecionada `iso-abbreviation=standard`. Opção selecionada `iso-author-punctuation=void`.


 ALMEIDA, J.; FRADE, M.; PINTO, J.; SOUSA, S. Melo de. 2011. An overview of formal methods tools and techniques. In _____. *Rigorous Software Development: An Introduction to Program Verification*. London: Springer London, p. 15–44. ISBN 978-0-85729-018-2. Available from Internet: http://dx.doi.org/10.1007/978-0-85729-018-2_2.

 ARORA, R.; SUMAN, S. 2012. Comparative analysis of classification algorithms on different datasets using weka. *International Journal of Computer Applications*, 2012, vol. 54, no. 13.


Referências VI


 ATZORI, L.; IERA, A.; MORABITO, G. 2010. The internet of things: A survey. *Computer Networks*, 2010, vol. 54, p. 2787–2805.


 BARRETT, J. 2012. *The Internet of Things - where the Web and the physical world will meet. TED x CIT, x = independently organized TED event*. Available from Internet: <<https://www.youtube.com/watch?v=QaTlt1C5R-M>>.

 BELQASMI, F.; FU, C.; GLITHO, R. 2011. Restful web services for service provisioning in next generation networks: A survey. *IEEE COMMUNICATIONS MAGAZINE, NETWORK and SERVICE MANAGEMENT*, 2011.


Referências VII


 BELQASMI, F.; SINGH, J; BANI MELHEM, S.; GLITHO, R. 2012. Soap-based web services vs. restful web services for multimedia conferencing applications: A case study. *IEEE INTERNET COMPUTING*, 2012. Available from Internet: <<http://spectrum.library.concordia.ca/980040/1-/PersonalCopy-SOAPvsREST.pdf>>.


 BLAND, J.; ALTMAN, D. 1996. Measurement error. *BMJ*, 1996, vol. 313, p. 744.

 CALDER, M.; KOLBERG, M.; MAGILL, E.H.; REIFF-MARGANIEC, S. 2003. Feature interaction: a critical review and considered forecast. *Computer Networks*, 2003, vol. 41, p. 115–141. Available from Internet: <<http://eprints.gla.ac.uk-/2874/1/feature1calder.pdf>>.


Referências VIII


 CHANDRAKANTH, S.; VENKATESH, K.; MAHESH, J.; NAGANJANEYULU, K. 2014. Internet of things. *International Journal of Innovations and Advancement in Computer Science IJIACS*, 2014, vol. 3.


 DAVIS, J.; GOADRIC, M. 2006. The relationship between precision-recall and roc curves. In *Proceedings of the 23rd International Conference on Machine Learning*. New York, NY, USA: ACM, (ICML '06), p. 233–240. ISBN 1-59593-383-2. Available from Internet: <<http://doi.acm.org/10.1145-1143844.1143874>>.

 DUSTDAR, S.; SCHREINER, W. 2005. A survey on web services composition. *Int. J. Web and Grid Services*, 2005, vol. 1, p. 1–30.


Referências IX


 ELIZONDO, D. 2006. The linear separability problem: Some testing methods. *IEEE TRANSACTIONS ON NEURAL NETWORKS*, 2006, vol. 17, no. 2. Available from Internet: <<http://sci2s.ugr.es/keel/pdf/specific/articulo/IEEETNN06.pdf>>.


 ENTERPRISE, INFO D.4 Networked; MICRO, RFID INFO G.2; NANOSYSTEMS. 2008. *Internet of Things in 2020: Roadmap for the Future*.

 FIRDAUSI, I.; LIM, C.; ERWIN, A.; NUGROHO, A. 2010. Analysis of machine learning techniques used in behavior-based malware detection. In *Advances in Computing, Control and Telecommunication Technologies (ACT)*, 2010 Second International Conference on. [S.l.: s.n.], p. 201–203.


Referências X


 FRANCA, T.; PIRES, P.; PIRMEZ, L.; DELICATO, F.; FARIAS, C. 2011. Web das coisas: Conectando dispositivos físicos ao mundo digital. In . Porto Alegre, RS: SBC: [s.n.]. vol. 1, p. 103–146.


 GUDGIN, M; HADLEY, M.; MENDELSON, N.; MOREAU, Jean-Jacques.; NIELSEN, Henrik F.; KARMARKAR, A.; LAFON, Y. 2007. *SOAP Version 1.2 Part 1: Messaging Framework (Second Edition)*. Available from Internet: <<https://www.w3.org/TR/soap12>>.


 GUINARD, D.; TRIFA, V. 2009. Towards the web of things: Web mashups for embedded devices. In *Workshop on Mashups, Enterprise Mashups and Lightweight Composition on the Web, International World Wide Web Conferences*. Madrid, Spain: [s.n.].


Referências XI

 HALL, M.; FRANK, E.; HOLMES, G.; PFAHRINGER, B.; REUTEMANN, P.; WITTEN, I. 2009. The weka data mining software: An update. *SIGKDD Explorations*, 2009, vol. 11.


 HEFFELFINGER, D. 2014. *Java EE 7 with GlassFish 4 Application Server*. Third. [S.I.]: Packt Publishing Ltd.


 KARTHIKEYAN, T.; THANGARAJU, P. 2013. Analysis of classification algorithms applied to hepatitis patients. *International Journal of Computer Applications*, 2013, vol. 62, no. 15.


 KERR, A.; HALL, H.; KOZUB, S. 2002. *Doing Statistics with SPSS*. [S.I.]: SAGE Publications. ISBN 0 7619 7384 2.


 KOTSIANTIS, S. 2007. Supervised machine learning: A review of classification techniques. *Informatica*, 2007, vol. 31, p. 249–268. Available from Internet: <<http://www.informatica.si/index.php/informatica/article/view/148/140>>.

Referências XII


 KUROSE, j.; ROSS, k. 2013. *COMPUTER NETWORKING A Top-Down Approach*. [S.l.]: PEARSON. ISBN 978-0-13-285620-1.


 MELVILLE, P.; MOONEY, R. J. 2003. Constructing diverse classifier ensembles using artificial training examples. In *Eighteenth International Joint Conference on Artificial Intelligence*. [S.l.: s.n.], p. 505–510.


 _____. 2004. Creating diversity in ensembles using artificial data. *Information Fusion: Special Issue on Diversity in Multiclassifier Systems*, 2004. Submitted.

 METZ, C. 1978. Basic principles of roc analysis. *Seminars in Nuclear Medicine*, 1978, vol. 8, no. 4, p. 283–298. ISSN 0001-2998. Available from Internet: <<http://www.sciencedirect.com/science/article/pii/S0001299878800142>>.


Referências XIII


 MICHIE, D.; SPIEGELHALTER, D.; TAYLOR, C. (Ed.). 1994. *Machine Learning, Neural and Statistical Classification*. [s.n.]. Available from Internet: <<http://www1.maths.leeds.ac.uk/~charles/statlog/>>.


 NAKAMURA, M.; IGAKI, H.; YOSHIMURA, Y.; IKEGAMI, K. 2009. Considering online feature interaction detection and resolution for integrated services in home network system. *Feature Interactions in Software and Communication Systems X*, 2009, p. 191–206.


 NAKAMURA, M.; IKEGAMI, K.; MATSUMOTO, S. 2013. Considering impacts and requirements for better understanding of environment interactions in home network services. *Computer Networks*, 2013, Elsevier, vol. 57, p. 2442–2453.

Referências XIV

 NHLABATSI, A.; LANEY, R.; NUSEIBEH, B. 2008. Feature interaction: the security threat from within software systems. *Progress in Informatics*, 2008, no. 5, p. 75–89. Available from Internet: <http://www.nii.jp/pi/n5/5_75.pdf>.

 OLSON, D.; DELEN, D. 2008. *Advanced Data Mining Techniques*. [S.l.]: Springer-Verlag Berlin Heidelberg. ISBN 978-3-540-76916-3.

 ORACLE. *What Is a URL?* Available from Internet: <<https://docs.oracle.com/javase/tutorial/networking/urls/definition.html>>.

 PAPAZOGLU, M. 2008a. *Slides from Web Services: Principles and Technology*. Available from Internet: <https://www.cs.colorado.edu/~kena/classes/7818/f08-/lectures/lecture_3_soap.pdf>.

Referências XV



_____. 2008b. *Web Services: Principles and Technology*. [S.l.]: Pearson. ISBN 978-0-321-15555-9.



PASINI, A. 2015. Artificial neural networks for small dataset analysis. *Journal of Thoracic Disease*, 2015, vol. 7, p. 953–960. Available from Internet: <<https://www.ncbi.nlm.nih.gov/pmc/articles/PMC4454870>>.





PAUTASSO, C. 2014. Restful web services: Principles, patterns, emerging technologies. In *Springer Science+Business Media*. New York: [s.n.]. Available from Internet: <<http://vis.uky.edu/~cheung/courses/ee586/papers/Pautasso2014.pdf>>.




PIYARE, R. 2013. Internet of things: Ubiquitous home control and monitoring system using android based smart phone. *International Journal of Internet of Things*, 2013, Elsevier, p. 5–11.


Referências XVI


 QUINLAN, Ross. 1993. *C4.5: Programs for Machine Learning*. San Mateo, CA: Morgan Kaufmann Publishers.


 SIEGMUND, N.; KOLESNIKOV, S.; KASTNER, C.; APEL, S.; BATORY, D.; ROSENMULLER, M.; SAAKE, G. 2012a. Predicting performance via automated feature-interaction detection. In *34th International Conference on Software Engineering (ICSE '12)*. Piscataway, NJ, USA: IEEE Press, p. 167–177.


 SIEGMUND, Norbert; ROSENMÜLLER, Marko; KUHLEMANN, Martin; KÄSTNER, Christian; APEL, Sven; SAAKE, Gunter". 2012b. Spl conqueror: Toward optimization of non-functional properties in software product lines. *Software Quality Journal*, 2012, vol. 20, no. 3, p. 487–517. ISSN 1573-1367. Available from Internet: <<http://dx.doi.org/10.1007/s11219-011-9152-9>>.


Referências XVII

 SUNDMAEKER, H.; GUILLEMIN, P.; FRIESS, P.; WOELFFLÉ, S. (Ed.). 2010. *Vision and Challenges for Realising the Internet of Things*. [S.l.]: European Union. ISBN 978-92-79-15088-3.


 THUM, T.; APEL, S.; KÄSTNER, C.; SCHAEFER, I.; SAAKE, G. 2014. A classification and survey of analysis strategies for software product lines. *ACM Comput. Surv.*, 2014, vol. 47.

 W3C. 2004a. *Extensible Markup Language (XML)*. Available from Internet: <<https://www.w3.org/XML/>>.


 _____. 2004b. *XML Schema*. Available from Internet: <<https://www.w3.org/XML/Schema>>.


 WEBER, Rolf. H.; WEBER, R. 2010. *Internet of Things - Legal Perspectives*. [S.l.]: Springer.

Referências XVIII




 WEISS, M.; ESFANDIARI, B.; LUO, Y. 2007. Towards a classification of web service feature interactions. *Computer Networks*, 2007, vol. 51, p. 359–381.

 WEISS, M.; ORESHKIN, A.; ESFANDIARI, B. *Invocation Order Matters: Functional Feature Interactions of Web Services*.

 _____. 2005. Invocation order matters: Functional feature interactions of web services. In *Proceedings of the First International Workshop on Engineering Service Compositions*. Amsterdam, The Netherlands: [s.n.], p. 69–76.

 WILSON, M.; MAGILL, E.; KOLBERG, M. 2005. An online approach for the service interaction problem in home automation. *Consumer Communications and Networking Conference*, 2005, IEEE.

Referências XIX

-  _____. 2008. Considering side effects in service interactions in home automation - an online approach. In _____. *Feature Interactions in Software and Communication Systems IX*. [S.l.]: IOS Press, p. 172–187. ISBN 978-1-58603-845-8.
-  WITTEN, I.; FRANK, E. 2005. *Data Mining: Practical Machine Learning Tools and Techniques*. second. [S.l.]: ELSEVIER. ISBN 0-12-088407-0.
-  ZHANG, G. 2000. Neural networks for classification: A survey. *IEEE TRANSACTIONS ON SYSTEMS, MAN, AND CYBERNETICS—PART C: APPLICATIONS AND REVIEWS*, 2000, vol. 30, no. 4.